

Fine-Tuning Implementation Plan — Al-Furqan

Supervised Learning with Human Feedback for Quranic Reasoning

Version 1.0

Project: Al-Furqan (الفرقان)

Date: March 22, 2026

Status: Plan Only — Execution pending data collection

Author: Arif AI + Muhammad Al-Ashmawy

Classification: Internal — Variance R&D

1. الهدف

مش بس تجيب معلومات عن — **التفكير التفسيري** متخصصة في Qwen تدريب نسخة من تربط الآيات ببعضها، ترجع للسيرة، تستخرج السنن الإلهية: **تفكر زي ما الشيخ يفكر** التفسير، بل وتستنبت الدروس.

المدخل: سؤال تفسيري

المخرج المطلوب: KB مع استخدام مصادر الـ (Axiom-guided) إجابة تتبع منهج تفكير محدد

المعيار: Human feedback (correct/wrong) على الإجابات

2. الكامل Training Pipeline الـ

Phase 1: Data Collection



3. Phase 1: Data Collection (الآن — مستمر)

3.1 مصادر البيانات

المصدر الأول: Pipeline Responses + Human Feedback

training example: ينتج pipeline كل سؤال يمر بالـ

```
{
  "question": "إليه علاقة أول أربع آيات بالآية 5؟",
  "system_prompt": "... أنت عالم متخصص [reasoning plan with axioms/gates]",
  "tool_calls": [
    {"name": "search_kb_by_verse", "args": {"verse_ref": "6:5"}, "result": "..."},
    {"name": "search_kb_by_topic", "args": {"topic": "السنة الإلهية"}, "result": "..."}
  ],
  "response": "...العلاقة هي مقدمة منطقية تؤدي لحتمية النتيجة...",
  "feedback": {
    "verdict": "correct_notes",
    "notes": "كويس بس ناقص ربط بحديث ابن مسعود",
  }
}
```

```
"reviewer": "muhammad"
}
```

KB من ال Synthetic Data: المصدر الثاني

KB entries: نوّلد أسئلة وإجابات مثالية من ال

```
KB Entry: 6:5 → يوم بدر (HAS_TAFSIR, confidence 0.95)
↓
Generated Q: "ما علاقة الآية الخامسة من سورة الأنعام بيوم بدر؟"
Generated A: (إجابة مبنية على ال KB entry + reasoning template)
↓
Human Review: correct ☐
```

المصدر الثالث: Preference Pairs (J DPO)

(chosen / rejected) نبني أزواج feedback من ال

```
Question: "تفسير الآية 6:5"
Chosen: (response rated "correct" – ذكر بدر + السنة الإلهية + حديث ابن مسعود)
Rejected: (response rated "wrong" – KB تفسير سطحي بدون )
```

الأهداف الكمية 3.2

المرحلة	عدد الأمثلة المطلوبة	المصدر
(أولي) SFT	500+	Pipeline responses (correct) + synthetic
(كامل) SFT	2,000+	+ more questions + باقي الحلقات
DPO	أزواج 300+	Pipeline (correct vs wrong pairs)

3.3 Training Format تصميم ال

SFT Format (Conversation):

```
{
  "conversations": [
    {
      "role": "system",
      "content": "المسلّمات ##\n... أنت عالم متخصص في تفسير القرآن"
    }
  ]
}
```

```

},
{
  "role": "user",
  "content": "إيه علاقة أول أربع آيات من سورة الأنعام بالآية رقم 5؟"
},
{
  "role": "assistant",
  "content": null,
  "tool_calls": [{"function": {"name": "search_kb_by_verse", "arguments": {"\verse_ref\
"},
{
  "role": "tool",
  "content": "## 6:5 الآية\nنتائج البحث عن الآية 6:5 [مع بدر، السنة الإلهية، حديث ابن مسعود]"
},
{
  "role": "assistant",
  "content": "...بناءً على البحث في قاعدة المعرفة... العلاقة هي مقدمة منطقية"
}
]
}

```

DPO Format (Preference Pairs):

```

{
  "prompt": "إيه علاقة أول أربع آيات بالآية 5؟",
  "chosen": "العلاقة هي مقدمة ونتيجة... [مع بدر + السنة الإلهية + حديث ابن مسعود]",
  "rejected": "KB, بدون [الآيات مترابطة]"
}

```

4. Phase 2: Data Curation

4.1 Data Pipeline

```

Raw Pipeline Outputs (data/tafsir_feedback/*.json)
↓
[Filter: correct + correct_notes only] → SFT candidates
↓
[Enhance: add ideal tool calls if missing]
↓
[Format: convert to conversation format]
↓
[Split: 80% train / 10% val / 10% test]
↓
training_data/
└─ sft_train.jsonl

```

```
|— sft_val.jsonl
|— sft_test.jsonl
|— dpo_train.jsonl
|— dpo_val.jsonl
```

4.2 Quality Filters

- **Include:** verdict = correct أو correct_notes
- **Exclude:** verdict = wrong (إلا كـ rejected في DPO)
- **Enhance:** tool calls نضيف → tools صح بس المودل ماستخدمش response لو الـ مثالية
- **Deduplicate:** أسئلة متشابهة → نختار الأفضل

4.3 Data Augmentation

- **Paraphrase questions:** نفس السؤال بصياغات مختلفة
- **Vary difficulty:** أسئلة بسيطة (تفسير آية) → معقدة (مقارنة سور)
- **Multi-turn:** أسئلة متتابعة (follow-up questions)

5. Phase 3: SFT (Supervised Fine-Tuning)

5.1 Model Selection

Model	Parameters	VRAM (Q4)	VRAM (LoRA Train)	Speed	Notes
Qwen3.5-9B- OmniCoder- Claude-Polaris	9B	~6GB	~16GB	50+ tok/s	— خفيف merge, مش reasoning- focused
Qwen3.5-27B- Claude-4.6- Opus- Reasoning- Distilled	27B	~16.5GB	~40GB	29-35 tok/s	التوصية

Model	Parameters	VRAM (Q4)	VRAM (LoRA Train)	Speed	Notes
Qwen3-32B	32B	~20GB	~48GB	20-25 tok/s	أصلي بدون distillation
Qwen3-30B-A3B (MoE)	30B (3B active)	~20GB	~40GB	سريع	أقل — MoE جودة reasoning

التوصية: Jackrong/Qwen3.5-27B-Claude-4.6-Opus-Reasoning-Distilled

Structured متدرب على — **1. Distilled من Claude Opus 4.6**: ليه هو الأنسب للفرقان. بالظبط نفس الأسلوب اللي محتاجينه: "1. حل السؤال → 2. Chain-of-Thought reasoning. 2 في الفهم والاستدلال باللغة B أقوى بكثير من الـ 9 — **27B**. 3. اربط → 4. استنبط" 2 يشتغل على — Q4_K_M quantization مع **16.5GB VRAM فقط**. العربية والنصوص الشرعية 3 يسع أي سؤال — **262K context window** 4. (RTX 3090/4090 أو A100 40GB) **واحد GPU يدعم**. استجابة سريعة للمستخدم 6 — RTX 3090 على **29-35 tok/s** 5. **tools** KB معقد + نتائج **Unslloth-** بتاعنا مباشرة 7 pipeline جاهز لـ — **thinking mode + tool calling** **optimized** — fine-tuning سهل الـ 8. **141K downloads + 1K likes** — المجتمع معتمد عليه ومختبر

Furqan-27B → DPO + SFT نعمل عليه → base المودل كـ

HuggingFace: Jackrong/Qwen3.5-27B-Claude-4.6-Opus-Reasoning-Distilled

GGUF: Jackrong/Qwen3.5-27B-Claude-4.6-Opus-Reasoning-Distilled-GGUF

5.2 Training Framework

LLaMA-Factory (Qwen مدعوم رسمياً من):

```
# config/sft_qwen3_14b_tafsir.yaml
model_name_or_path: Qwen/Qwen3-14B
dataset: tafsir_sft
template: qwen3
finetuning_type: lora
lora_rank: 64
lora_alpha: 128
lora_target: all
learning_rate: 1.0e-4
num_train_epochs: 3
per_device_train_batch_size: 2
```

```
gradient_accumulation_steps: 8
bf16: true
max_length: 8192
logging_steps: 10
save_steps: 100
eval_steps: 100
```

5.3 LoRA vs Full Fine-Tuning

Method	VRAM	Training Time	Quality	When to use
QLoRA (4-bit)	~20GB	ساعات	85-90%	واحد GPU — التجربة الأولى
LoRA	~40GB	ساعات	90-95%	بعد التجربة الأولى — نتائج أحسن
Full FT	~120GB+	أيام	100%	لما نكون واثقين من البيانات

لنسخة النهائية LoRA عشان نجرب بسرعة، وبعدين QLoRA نبدأ بـ: **التوصية**

5.4 What the Model Learns in SFT

مهارات 3 المودل بيتعلم

- ولماذا tool متى يستخدم أي: **إزاي يبحث**
- `search_kb_by_verse` يشوف السؤال عن آية
- `search_kb_by_topic` "يشوف كلمة" السنة الإلهية
- `search_kb_by_relation(verse, "LINKED_HADITH")` يحتاج أحاديث
- reasoning template يتبع الـ: **إزاي يفكر**
- يبدأ بالسياق → يحدد الموضوع → يربط → يستنبط
- في تحليله Axioms يطبق الـ
- قبل الإجابة Gates يتحقق من الـ
- أسلوب الإجابة المثالي: **إزاي يجاوب**
- KB يدمج معرفته مع الـ
- ينسب المعلومات لمصادرها

6. Phase 4: DPO (Direct Preference Optimization)

6.1 لماذا DPO بعد SFT؟

SFT يعني يتجنب الأخطاء — **يفضّل الصح على الغلط** يعلّمه DPO. **إليه الإجابة الصح** يعلّم المودل SFT. feedback الشائعة اللي لقيناها في الـ

6.2 بناء Preference Pairs

feedback data من الـ

```
Same question, two responses:
├─ Chosen (correct/correct_notes):
│   "...العلاقة تتضح من خلال السنة الإلهية"
│   "...كما ذكر الشيخ أحمد السيد في ربطه بيوم بدر"
└─ Rejected (wrong/wrong_notes):
    "...الآيات مترابطة بشكل عام"
    "...فالآية 5 تكمل ما قبلها"
```

Pipeline 2. (مختلفة runs من) **نفس السؤال** — **إجابتين مختلفتين** 1. **Pairs: مصادر الـ**
response vs Zero-shot (مع KB vs بدون KB) 3. **Synthetic rejected:** **ناخذ إجابة صح ونشيل**
KB references منها الـ

6.3 DPO Training Config

```
# config/dpo_qwen3_14b_tafsir.yaml
model_name_or_path: output/sft_checkpoint # ← start from SFT model
dataset: tafsir_dpo
template: qwen3
finetuning_type: lora
pref_loss: sigmoid # DPO loss
pref_beta: 0.1
learning_rate: 5.0e-5
num_train_epochs: 1
per_device_train_batch_size: 1
gradient_accumulation_steps: 16
bf16: true
```


6.4 What DPO Teaches

Pattern to Learn	Chosen	Rejected
KB استخدم الـ	ذكر بدر + حديث ابن مسعود	تفسير عام بدون مصادر
انسب المصادر	"...كما ذكر الشيخ أحمد السيد"	بدون نسبة
Axioms اتبع الـ	Design + Network Effect ربط بالـ	تحليل عشوائي
Gates تحقق من	"...يحقق بوابة الاتساق الهيكلي"	self-check بدون
Tools استخدم	مناسبة 5-8 tool calls	أو بحث عشوائي 0 tool calls

7. Phase 5: Evaluation

7.1 Benchmark Suite

اللي عملناه + أسئلة جديدة **12-question benchmark** نستخدم نفس الـ

Eval Set	عدد الأسئلة	الغرض
Core Benchmark	12	(zero-shot vs SFT vs DPO) المقارنة الأساسية
KB Coverage	30	صح؟ KB هل المودل بيستخدم الـ
Tool Usage	20	الصح؟ tools هل بيختار الـ
Axiom Alignment	15	في تفكيره؟ Axioms هل يطبق الـ
Edge Cases	10	KB أسئلة غريبة / مش في الـ

7.2 Metrics

Metric	How	Target
Accuracy	Human review (correct %)	≥ 85%
KB Usage	Tool calls per question	≥ 3

Metric	How	Target
Alignment	Human rating 1-5	≥ 4.5
Depth	Human rating 1-5	≥ 4.5
Source Attribution	% responses citing sources	$\geq 90\%$
Gate Compliance	% responses self-checking gates	$\geq 80\%$
Latency	Response time	$\leq 15s$ (local GPU)

7.3 A/B Testing

Same questions, 3 models:

- └─ Base Qwen3-14B (zero-shot) → baseline
- └─ SFT Qwen3-14B (after Phase 3) → +KB +reasoning
- └─ DPO Qwen3-14B (after Phase 4) → +preferences

8. Infrastructure

8.1 GPU Requirements

Phase	GPU	VRAM	Estimated Time	Cost (cloud)
SFT (QLoRA)	1× A100 40GB	24GB	2-4 hours	~\$10-20
SFT (LoRA)	1× A100 80GB	40GB	4-8 hours	~\$30-60
DPO (LoRA)	1× A100 80GB	40GB	2-4 hours	~\$20-40
Inference	1× A100 40GB	28GB	—	~\$2/hour
Total Training			~8-16 hours	~\$60-120

8.2 Software Stack

Training:

- └─ LLaMA-Factory – training framework (Qwen-recommended)

```

└─ PEFT – LoRA/QLoRA adapters
└─ DeepSpeed ZeRO-2 – memory optimization
└─ bitsandbytes – 4-bit quantization (for QLoRA)
└─ Weights & Biases – experiment tracking

Inference:
└─ vLLM – high-throughput serving
└─ SGLang – alternative (better tool calling support)

Data:
└─ proposed_edges.db – KB source
└─ tafsir_feedback/ – human reviews
└─ training_data/ – formatted datasets

```

8.3 On-Premises vs Cloud

Option	Pros	Cons	Cost
Cloud (RunPod/ Lambda)	سهل، مرن سريع	مؤقت، بيانات على سيرفر خارجي	~\$2-3/hour per A100
Mjara Cloud (own infra)	بياناتنا عندنا مستمر	setup محتاج	استثمار أولي
Colab Pro	رخيص	GPU ضعيف (T4/A100 40GB)	\$10-50/شهر

Mjara للتجارب الأولى، وبعدين ننقل لـ **RunPod** (A100 80GB, ~\$2.5/hour) نبدأ بـ: **التوصية** production. لما نكون مستعدين لـ **Cloud**.

9. Timeline

(الآن — أسابيع 4-1): Prerequisites

- تنزيل وتفريغ الحلقات الـ 22 الباقية []
- KB entries استخراج الـ (~1,500+ entry) []
- pipeline من الـ human feedback + جمع 100 []
- training قبل أي **لازم تخلص** هذه المرحلة []

Phase 1: Data Collection (أسابيع 1-6):

- على أسئلة متنوعة (50+ سؤال/أسبوع) pipeline تشغيل ال []
- verdicts بال 4 human feedback جمع []
- 500+ reviewed response: الهدف []

Phase 2: Data Curation (أسبوع 7):

- تنظيف البيانات وتقسيمها []
- preference pairs بناء []
- Validation set مستقل []

Phase 3: SFT Training (أسبوع 8):

- (ساعات 2-4 Qwen3-14B, تجربة أولى QLoRA) []
- benchmark على ال Evaluation []
- LoRA (ساعات 4-8) النتائج واعدة []

Phase 4: DPO Training (أسبوع 9):

- feedback من ال preference pairs بناء []
- (ساعات 2-4) DPO training []
- A/B comparison: Base vs SFT vs DPO []

Phase 5: Evaluation & Iteration (أسبوع 10):

- (سؤال 87) Full benchmark []
- Error analysis []
- Iteration if needed []

من بداية جمع البيانات لأول مودل مُدَرَّب أسابيع 10~: الإجمالي


10. المخاطر والحلول

المخاطر	الاحتمال	الحل
Data قليلة	عالي	Synthetic data augmentation + paraphrasing
مش كفاية JIB 14	متوسط	MoE 30B-A3B أو B جرب 32
Tool calling يتكسر بعد SFT	متوسط	tool format + eval تدريب محدد على
Overfitting على حلقة 1	عالي	final model لازم 23 حلقة قبل الـ
Arabic tokenization ضعيفة	منخفض	ممتاز في العربي أصلاً Qwen
Catastrophic forgetting	متوسط	(يحافظ على المعرفة الأصلية) LoRA
الأحاديث الضعيفة	متوسط	Source-Integrity Gate + human review

11. Success Criteria

Criterion	Metric	Target
KB النموذج يستخدم الـ	Tool calls / question	≥ 3
النموذج يربط بالسيارة	% responses with seerah link	$\geq 70\%$
النموذج ييذكر المصادر	% with source attribution	$\geq 90\%$
Axioms النموذج يتبع الـ	Axiom alignment score	$\geq 4/5$
base النموذج أحسن من	Human preference (win rate)	$\geq 70\%$ vs base
سرعة الاستجابة	Time to first token	$\leq 2s$ (local)
Human accuracy	% correct in production	$\geq 85\%$

12. Architecture بعد ال Fine-Tuning



متدرب) أدق - (per-token cost مفيش) أرخص - (local GPU vs API) xأسرع 3-10 - الفرق
QLP v3.0 متوافق مع - (البيانات ماتروحش لسيرفر خارجي) خصوصية - (على منهج الشيخ تحديداً
(سيادة رقمية + Local-First)

13. الخلاصة

خاص بينا بنبني نموذج تفكير تفسيري مش مجرد "نحسن النتائج" — ده Fine-tuning ال

1. pipeline + human feedback عالية الجودة من ال data نجمع: الآن
2. نعلّمه إزاي يجاوب صح — SFT example: +بعد 500
3. نعلّمه يفضل الصح على الغلط — DPO pair: +بعد 300
4. متخصص في التفكير التفسيري (مبني على local نموذج — Furqan-27B النتيجة: Qwen3.5-27B-Claude-Opus-Distilled)

للمنموذج بتاعنا بكرة training data = بيتكتب feedback كل سؤال بيتسأل النهارده + كل